

Dabout Mattéo

ING2

Finance Alternance

Projet Data Science For Finance

Mémoire sur l'approche et les résultats

Introduction :

Ce projet est réalisé dans le cadre du module « Data Science For Finance ».

Il a pour ambition de concevoir une stratégie d'investissement allant d'une base de données brutes jusqu'à l'évaluation de la performance de la stratégie.

La méthodologie autour de ce projet s'articule autour de quatre axes majeurs qui sont :

- Le prétraitement et le « Feature Engineering ». Le but est de rendre les données propres, de convertir les différentes devises vers la devise euro et de calculer certains indicateurs qui seront utiles dans le reste du projet comme le RSI, la Volatilité ou encore le Ichimoku.
- La régression des données. Le but est d'évaluer la sensibilité des actifs face à des indices de références pour comprendre leur comportement de marché.
- La segmentation ou « Clustering ». Le but est d'identifier des groupes d'actifs aux profils de risque et/ou de rendement similaires pour optimiser la diversification.
- La classification. Le but est d'utiliser différents algorithmes supervisés pour prédire la direction des cours de marché et adopter une stratégie de trading active efficace.

Le socle de cette analyse va s'appuyer sur trois sources de données distinctes qui sont :

- Une source apportée par notre professeur qui est le fichier Excel « UniversInvestissement » comprenant différents ticker avec des informations qualitatives sur ces ticker.
- Une source apportée par notre professeur qui est le fichier Parquet « univers-prix » qui comprend le prix des différents ticker dans leur devise d'origine sur un ensemble de dates.
- Une source externe (ici Yfinance) qui nous permettra de récupérer les taux de change (EUR/USD, EUR/GBP, EUR/CHF) nécessaires à la conversion monétaire, ainsi que les principaux indices boursiers mondiaux (S&P500, EuroStoxx 50, CAC 40).

L'architecture du code a été simplifiée, nous avons deux fichiers :

- Le fichier « main.py » comprenant l'ensemble du Backend du projet codé en Python
- Le fichier « dashboard.py » comprenant l'ensemble du Frontend du projet codé en Python/Streamlit

Partie 1 – Préparation des données et Feature Engineering :

Dans un projet de cette envergure, la qualité de nos résultats est basée sur un pilier essentiel qui est la qualité de nos données. Si nos données sont erronées, non standardisées ou non alignées, alors les résultats seront incohérents. Cette première partie détaille le pipeline de traitement rigoureux mis en place pour transformer des prix bruts en signaux exploitables.

1) Nettoyage et Alignement temporel

Nous avons eu recours à un ensemble d'actifs étant cotés sur différents marchés boursiers. Ainsi, certains jours chômés aux USA ne sont pas les mêmes qu'en Europe et inversement. Il était donc nécessaire d'aligner nos dates et de combler les trous. Pour faire cela, nous avons eu besoin de deux méthodes. Soit : Forward Fill (ffill) ; pour combler les trous de cotation (week-ends ou jours fériés), nous avons propagé le dernier prix connu. Financièrement, cela signifie que la valeur de l'actif reste stable jusqu'à la prochaine transaction. Ou alors, Backward Fill (bfill) ; utilisé de manière marginale pour traiter d'éventuelles données manquantes en tout début de période.

2) Standardisation Monétaire

Pour comparer des choses qui le sont vraiment. Nous avons eu besoin d'utiliser des taux de change pour passer tout nos actifs sous une seule et même devise, l'euro. Nous avons donc intégré les taux de change dynamiques via l'API *yfinance* pour convertir chaque prix historique en euros selon la formule :


$$P_{t,eur} = P_{t,devise} / FX_{t,eur/devise}$$

3) Feature Engineering

En finance, on ne travaille jamais sur les prix directement mais sur les rendements, ici nous prenons les log-rendements ($\ln(p_t/p_{t-1})$).


Pour permettre à nos modèles de capturer la psychologie du marché et les tendances, nous avons enrichi nos données avec des variables explicatives standard :

- La moyenne mobile (MA20) : qui permet d'identifier la tendance de fond en lissant les bruits
- Le Ichimoku Tenkan : Indicateur de l'équilibre de court terme du prix.




Graphique avec Prix en Euro, MA20 et Ichimoku Tenkan

- Le RSI : indiquant si un titre est dans un moment de surachat ou de survente



Graphique avec le RSI (Momentum 14 jours)

- La volatilité glissante (20 jours) : mesurant le risque / l'incertitude lié à l'actif



Graphique avec la Volatilité 20 jours

Partie 2 – La Régression Linéaire :

Après avoir nettoyé et enrichi nos données, la première étape de notre analyse quantitative de ces données est la régression linéaire multiple. Cette dernière permet de comparer un actif à un grand indice de marché. Cela permet aussi de quantifier la sensibilité d'un titre (le rendement dépendant) par rapport à des benchmarks (les variables indépendantes).

1) Construction du modèle

Nous utilisons ici l'algorithme des moindres carrés ordinaires de scikit-learn. Nous pouvons ainsi effectuer une régression des log-rendements de l'actif étudié avec les rendements de certains indices boursiers très populaire comme :

- L'EuroStoxx 50 (STOXX50E) : Représentant le risque de marché de la zone Euro.
- Le S&P 500 (GSPC) : Représentant la dynamique du marché américain.

L'équation du modèle est donc : $R_{\text{actif}} = a + B_1 R_{\text{Europe}} + B_2 R_{\text{US}} + \text{eps}$


2) Interprétation des coefficients

Le but de cette régression réside dans l'interprétation des coefficients trouvés.

- Le Beta mesure la sensibilité de l'actif aux mouvements du marché.

Par exemple, un Beta de 1 indique que l'actif évolue exactement comme le marché.

Un Beta > 1 amplifie les mouvements du marché et un Beta < 1 les amortit.



Exemple d'exposition (Beta) du DPAM B Equities Euroland B

- L'Alpha, c'est le rendement que l'actif obtiendrait si les indices de marché restaient stables. Un Alpha positif est le signe d'une capacité de l'actif à générer de la performance par lui-même.



Exemple de l'Alpha de ce même actif

3) Analyse de la pertinence du modèle

Nous avons choisi d'afficher systématiquement le R^2 . En effet, cet indicateur est crucial il permet de mesurer le pourcentage de la variance de l'actif expliqué par nos variables indépendantes (ici les indices).

Un R^2 élevé (proche de 1) implique que l'actif suit le marché.


Un R^2 faible (proche de 0) suggère que l'actif est décorrélé des indices choisis, impliquant qu'il est soit très spécifique, soit lié à d'autres facteurs de risque.

R^2 Score
0.8804

Exemple du R^2 du même actif (très élevé)

4) Visualisation Réels Vs Prédits

Pour valider visuellement notre régression, nous avons choisi d'afficher un graphique représentant l'ensemble des points réels de l'actif Vs la prédiction donnée par la régression linéaire. La proximité des points autour de la droite de régression idéale permet de juger immédiatement de la fiabilité de nos coefficients Beta.



Graphique pour cet actif de la régression linéaire

Partie 3 – La Segmentation ou Clustering K-Means

L'objectif de notre clustering dans le cadre de ce projet est de regrouper les actifs non pas par secteur mais par comportement financier réel. Cette approche permet de découvrir des similarités entre des entreprises de secteurs différents mais partageant des profils de risque identiques.

1) Méthodologie

Au lieu de faire notre clustering sur les rendements, nous l'avons effectué sur 4 critères particuliers qui sont :

- Le Rendement Annualisé : Mesure de la performance historique.
- La Volatilité Annualisée : Mesure du risque de marché.
- Le Maximum Drawdown : Mesure du risque de perte maximale.
- Le Beta de Marché : Mesure de la sensibilité à l'indice de référence.


2) La standardisation

Ici nous comparons des critères qui ne vivent pas sur les mêmes échelles. En effet, un Beta peut être de 1,2 alors qu'un rendement annualisé va être aux alentours des 10% ou 20%. Ainsi, il était nécessaire de standardiser toutes nos variables pour les rendre comparable / exploitable.

3) Analyse des clusters et profils types

Grâce à ce clustering, nous segmentons l'univers en plusieurs groupes. Cela permet grâce à l'analyse des centres de gravité d'identifier des profils types :

- Cluster "Défensif" : Caractérisé par une volatilité faible et un Beta inférieur à 1. Ces actifs protègent le portefeuille en cas de baisse du marché.
- Cluster "Performance/Risqué" : Regroupe des actifs avec des rendements élevés mais souvent accompagnés d'un Max Drawdown important.
- Cluster "Neutre" : Actifs dont le comportement est proche de la moyenne du marché.



Graphique d'un nuage de points avec 4 clusters (Risque vs Rendement)



Profil moyen par Cluster

Cluster	Rendement_Ann	Volatilite_Ann	Max_Drawdown	Beta_Marche
0	1.53%	9.27%	-22.48%	15.01%
1	2.47%	3353.23%	-2640.98%	419.82%
2	5.21%	18.82%	-39.83%	64.01%
3	-35.95%	347.39%	-338.69%	-16.49%

Profil Moyen des clusters du graphique précédent

4) Utilité Stratégique

L'intérêt de ce clustering réside dans ces deux points :

- L'Identification de Paires : Si deux actifs sont dans le même cluster, ils sont redondants. Pour diversifier, il vaut mieux choisir des actifs appartenant à des clusters différents.
- L'Allocation Tactique : En fonction du contexte macroéconomique, un investisseur pourra privilégier le "Cluster Défensif" ou le "Cluster Croissance".

Partie 4 – La Classification et la Stratégie d'Investissement

L'étape finale de ce projet consiste à tenter de prédire la direction future des prix pour construire une stratégie de trading active. La classification vise à répondre à une question binaire : « Le prix de l'actif sera-t-il plus élevé demain qu'aujourd'hui ? ».

1) Méthodologie


Dans le cadre de notre Machine Learning pour cette partie pour éviter tout biais d'anticipation, nous avons pris des règles strictes :

- Time Series Split : Nous avons utilisé les 80 premiers % de nos données chronologiques pour l'entraînement de notre modèle et les 20 % les plus récents pour l'évaluation. Cette méthode permet d'assurer que le modèle apprend du passé pour prédire le futur.
- Variables explicatives : Le modèle s'appuie sur le Feature Engineering réalisé précédemment : RSI, volatilité, performance glissante et rendements décalés sont utilisés. Ces derniers permettent au modèle de détecter si une dynamique de court terme (hausse pendant plusieurs jours de suite) pourrait influencer la probabilité de hausse du lendemain.

2) Evaluation Technique

Pour juger de la pertinence de notre modèle, deux indicateurs ont été choisis :

- La Matrice de Confusion. Elle permet de décomposer les erreurs du modèle. En finance, un « Faux Positif » (prédire une hausse alors que le cours baisse) est coûteux car il entraîne une perte en capital. À l'inverse, un « Faux Négatif » (prédire une baisse alors que le cours monte) représente un coût d'opportunité. Nos tests révèlent souvent un biais haussier : les modèles ont tendance à prédire la hausse massivement, reflétant la tendance historique positive des marchés actions.



Matrice de Confusion (Algorithme Random Forest et Actif étudié précédemment)

- Le Score F1. L'exactitude globale (Accuracy) est souvent mauvaise en finance. Nous avons donc choisi le Score F1, c'est la moyenne harmonique de la précision et du rappel. Un Score F1 équilibré indique que le modèle est capable d'identifier les hausses sans générer un nombre excessif de faux signaux. Un score proche de 1 est très positif, le modèle détecte bien tout sans se tromper, à l'inverse un score proche de 0 signifie que le modèle est médiocre.

1. Modélisation (Machine Learning)

Précision Globale (Accuracy)

50.17%

Score F1

0.5552


Précision et Score F1 de ce modèle

3) Evaluation Financière

La finalité de ce projet est la comparaison entre notre stratégie et la stratégie de référence : le Buy & Hold.

Différents KPI's nous permettent d'analyser la performance de notre stratégie :

- La Performance Totale : On observe souvent que la stratégie passive surperforme la nôtre. Cela s'explique par le fait que le modèle, en cherchant à éviter les baisses, finit par rater les quelques jours de forte hausse qui constituent l'essentiel de la performance à long terme.
- La Volatilité et le Max Drawdown : C'est ici que notre modèle peut se révéler utile. En sortant du marché lors de périodes risquées, il affiche souvent une volatilité plus faible et un risque de perte maximale réduit par rapport au marché pur.
- La Corrélation : Notre stratégie peut présenter une faible corrélation avec l'indice de référence, ce qui peut en faire un outil de diversification intéressant dans un portefeuille global.



Courbe de Rendement (Marché Vs Stratégie IA)

2. Évaluation des Performances et des Risques

Comparatif strict entre la stratégie générée par l'IA et la conservation passive de l'actif (Buy & Hold).

Indicateur	Stratégie IA	Marché (Buy & Hold)
Performance Totale	5.69%	19.53%
Volatilité Annualisée	12.28%	15.13%
Perte Maximale (Max Drawdown)	-15.70%	-17.21%
Corrélation avec l'Indice EuroStoxx50	0.76	1.00

Comparatif strict entre les deux stratégies

4) Conclusion Critique

Les résultats obtenus pour la précision sont souvent aux alentours des 50%. Cela démontre que notre modèle a raison une fois sur deux et qu'un modèle magique n'existe pas ou en tout cas que nous ne l'avons pas trouvé. Cela démontre ainsi l'efficacité des marchés.

De plus, la Stratégie est souvent moyenne : Le modèle génère du profit, mais sous-performe la simple stratégie de conservation (Buy & Hold) sur la période.

Toutefois, ce travail démontre que le Machine Learning est un outil puissant comme filtre de gestion des risques. Si l'IA ne bat pas systématiquement le marché en rendement pur, elle offre une approche systématique et émotionnellement neutre.

Conclusion :

En conclusion, même si le Machine Learning ne remplace pas l'expertise humaine, ce projet démontre qu'il est un allié indispensable pour systématiser l'analyse, éliminer les biais émotionnels et structurer une gestion de portefeuille moderne et rigoureuse.

L'analyse de nos résultats met en évidence plusieurs limites à ce projet :

- La "Marche Aléatoire" : La précision de nos modèles de classification (souvent proche de 50 %) confirme l'hypothèse d'efficience des marchés. Le prix passé ne contient pas toujours suffisamment d'information pour prédire le prix futur.
- L'absence de coûts de transaction : Notre simulation de backtest est "brute". Dans la réalité, les frais de courtage et le "slippage" pourraient réduire significativement la performance de la stratégie IA, surtout si elle génère beaucoup de signaux d'achat/vente.
- Le biais de survie et de données : Nos modèles s'appuient uniquement sur des données de prix. Ils ignorent les événements macroéconomiques majeurs qui peuvent rendre caduques les indicateurs techniques en une fraction de seconde.

Ainsi, pour transformer ce projet en véritable outil de trading institutionnel, différentes évolutions sont à envisager, comme :

- L'Intégration du NLP (Natural Language Processing) : Ajouter un module d'analyse de sentiment qui traite les flux d'actualités financières ou les rapports annuels pour anticiper les mouvements de marché avant qu'ils ne se reflètent réellement dans les prix.
- L'Intégration de Données Alternatives : Enrichir le modèle avec des données extra-financières (données ESG, volumes de recherche Google Trends, flux de transport maritime) pour obtenir un avantage informationnel.