

Projet – Datascience en finance (Python) - 2026

Date limite du projet :

- 31 mai à 23h59 (heure de Paris), chaque jour de retard (-20% de la note maximale).
- *Procédure de restitution du projet communiqué dans une annexe.*

Attentes de rendu :

- Mémoire d'une dizaine de pages de votre approches et de vos résultats
- Codes Python, données utilisées et extraction des résultats
- *Nice to have : tableau de bord Streamlit*

Objectifs du projet :

- Utiliser les différents modèles de datascience vus en cours (régression, classification, clustering)
- Construire une stratégie d'investissement face à un indice de marché (exemple le CAC40)
- *NB : La performance de votre stratégie n'est pas corrélé à votre note, c'est l'approche utilisée importe davantage.*

1. Récupération des données

Dans le cadre de ce projet, des données de prix d'actions, de taux de change et d'indices sont fournis.

Il vous est demandé d'appliquer les retraitements usuels (calcul log-returns, données manquantes, ...).

Attention, les prix sont associés à une devise, il faut les convertir en euros avant toute analyse.

Par exemple si le prix en t en usd est de $p_{t,USD}$, alors le prix en euros en t dépend du taux de change EUR/USD

$f_{x_{t,EUR/USD}}$ en t : $p_{t,EUR} = p_{t,USD} / f_{x_{t,EUR/USD}}$.

Pour certains modèles, il peut être judicieux de créer des variables explicatives supplémentaires à partir des prix : indicateurs techniques (RSI, moyennes mobiles, Ichimoku, performance glissante) ou volatilité glissante.

2. Mise en place des modèles de DataScience

L'implémentation doit respecter une séparation stricte des données de **Train** (entraînement) et de **Test** (évaluation) en respectant la chronologie (Time Series Split).

- **Feature Engineering** : Avant la modélisation, créez des variables explicatives (indicateurs techniques, rendements décalés, volatilité) pour enrichir vos modèles.
- **Modèle de régression linéaire** : Afin de réduire la dimension de vos données, vous pouvez effectuer une régression sur les indices sectoriels. Commentez la pertinence des coefficients, les expositions et vos résultats.
- **Clustering** : Regrouper les actifs par profil de risque/rendement, par critères ou par comportement sectoriel (ex de modèle : K-Means, Clustering Hiérarchique, DBSCAN, ...). Cette étape peut vous permettre d'identifier des « paires » d'actifs corrélés, de diversifier un portefeuille en choisissant un actif par cluster ou de segmenter l'univers d'investissement. Attention, ce clustering doit être effectué sur des caractéristiques (coefficients de régression linéaire, performance, volatilité, indicateurs techniques) et non sur les séries temporelles.

- **Classification** : Prédire à partir de critères si le marché va aller à la hausse, ou à la baisse (ex : regression logistitique, SVM, ...). Portez une attention particulière à la matrice de confusion et au score F1.

3. Éléments d'évaluation de la performance du portefeuille

Vous pouvez utiliser les indicateurs classiques pour évaluer les risques et les performances de votre / vos stratégies (max drawdown, volatilité, performance totale ou par période, corrélation par rapport à un indice ...).